LAPORAN PROYEK MACHINE LEARNING

TELCO CUSTOMER CHURN CLASSIFICATION

Prediksi Pelanggan yang Berpotensi Berhenti Berlangganan

Disusun oleh
Mohamad Ezza Fisabili

Program Studi Teknik Informatika
Universitas Dian Nuswantoro
2026

RINGKASAN EKSEKUTIF

Proyek ini menerapkan Machine Learning untuk memprediksi apakah pelanggan layanan telekomunikasi berpotensi berhenti berlangganan (customer churn). Tiga algoritma dibandingkan: Logistic Regression, Decision Tree, dan Random Forest. Berdasarkan hasil yang diberikan, Logistic Regression memperoleh performa terbaik pada seluruh metrik yang dilaporkan: Accuracy 79,99%, Precision 65,44%, Recall 52,14%, dan F1-Score 58,04%.

Analisis Permutation Feature Importance menunjukkan tenure sebagai fitur terpenting (0,195386), diikuti InternetService (0,111788) dan Contract (0,111738). Meskipun Logistic Regression menjadi model terbaik di antara tiga model yang diuji, Recall 52,14% menunjukkan masih banyak pelanggan churn yang tidak terdeteksi. Model perlu disempurnakan sebelum digunakan sebagai dasar keputusan operasional.

1. PENDAHULUAN

1.1 Latar Belakang

Customer churn adalah kondisi ketika pelanggan berhenti menggunakan layanan perusahaan. Dalam industri telekomunikasi, churn dapat memengaruhi pendapatan dan hubungan jangka panjang dengan pelanggan. Machine Learning dapat membantu perusahaan mengenali pola pelanggan yang berpotensi berhenti berlangganan sehingga strategi retensi dapat dipertimbangkan lebih awal.

1.2 Rumusan Masalah dan Tujuan

Proyek ini menjawab bagaimana membangun model klasifikasi customer churn, membandingkan performa beberapa algoritma, serta mengidentifikasi fitur yang paling berkontribusi terhadap prediksi. Tujuannya adalah memahami data, melakukan persiapan data, melatih model, mengevaluasi hasil, dan menyusun rekomendasi bisnis.

2. DESKRIPSI DATASET

Dataset yang digunakan adalah Telco Customer Churn. Target prediksi adalah kolom Churn: Yes berarti pelanggan berhenti berlangganan dan No berarti pelanggan tidak berhenti. Dalam pemodelan, target dikonversi menjadi Yes = 1 dan No = 0. Atribut yang digunakan mencakup informasi pelanggan, layanan, kontrak, pembayaran, masa berlangganan, dan biaya. Contoh fitur numerik adalah tenure, MonthlyCharges, dan TotalCharges; fitur kategorikal antara lain Contract, InternetService, OnlineSecurity, TechSupport, dan PaymentMethod.

Jumlah baris dan kolom aktual dari output Stage 1 belum diberikan saat laporan ini disusun. Angka tersebut perlu ditambahkan dari hasil notebook agar laporan tidak mencantumkan jumlah observasi yang belum diverifikasi.

3. METODOLOGI DAN PERSIAPAN DATA

3.1 Data Understanding dan EDA

Data Understanding memeriksa preview, dimensi dataset, tipe data, statistik deskriptif, missing values, duplikasi, dan distribusi target. EDA mengeksplorasi distribusi churn serta pola berdasarkan tenure, MonthlyCharges, TotalCharges, Contract, InternetService, dan PaymentMethod, termasuk korelasi fitur numerik. Angka rinci dan grafik EDA aktual belum disertakan dalam bahan hasil yang diterima, sehingga bagian ini menjelaskan cakupan analisis tanpa mengklaim pola yang belum diverifikasi.

3.2 Data Cleaning

Kolom TotalCharges dikonversi menjadi numerik. Untuk pelanggan dengan tenure = 0 dan TotalCharges kosong, nilai diisi 0. Missing value TotalCharges yang masih tersisa diisi dengan median. Data duplikat diperiksa dan dihapus apabila ditemukan.

Catatan metodologis: pada alur kode awal, median dihitung sebelum train-test split. Untuk menghindari potensi data leakage, imputasi sebaiknya dilakukan di dalam pipeline dan di-fit hanya menggunakan data training.

3.3 Feature Engineering dan Preprocessing

Fitur tenure_group dibuat dengan kelompok 0–12, 13–24, 25–48, 49–60, dan 61–72 bulan. Kolom customerID dikeluarkan karena hanya merupakan identitas pelanggan. Data dibagi menjadi 80% training dan 20% testing dengan

random_state = 42 serta stratify = y. Fitur numerik diproses dengan StandardScaler dan fitur kategorikal menggunakan OneHotEncoder. Proses preprocessing digabungkan dengan model melalui Pipeline.

4. PENGEMBANGAN MODEL

Logistic Regression digunakan untuk memodelkan probabilitas kelas churn. **Decision Tree** membentuk aturan keputusan berdasarkan fitur, dengan max_depth = 8. **Random Forest** menggabungkan banyak Decision Tree, dengan 100 estimator dan max_depth = 12. Ketiga model dilatih menggunakan data training yang sama dan dievaluasi pada data testing yang sama.

5. HASIL DAN EVALUASI MODEL

5.1 Perbandingan Metrik

Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	79,99%	65,44%	52,14%	58,04%
Decision Tree	77,36%	58,46%	50,80%	54,36%
Random Forest	79,56%	64,43%	51,34%	57,14%

5.2 Interpretasi

Logistic Regression memiliki nilai tertinggi pada Accuracy, Precision, Recall, dan F1-Score di antara model yang dibandingkan. Accuracy mengukur proporsi seluruh prediksi yang benar. Precision mengukur ketepatan prediksi churn. Recall mengukur seberapa banyak pelanggan yang benar-benar churn berhasil ditemukan. F1-Score menyeimbangkan Precision dan Recall.

Recall 52,14% berarti model menemukan sekitar 52 dari setiap 100 pelanggan yang benar-benar churn pada data testing, pada threshold klasifikasi yang digunakan. Sekitar 48 dari setiap 100 pelanggan churn tidak terdeteksi. Ini merupakan kelemahan penting jika tujuan bisnis adalah menemukan sebanyak mungkin pelanggan berisiko.

5.3 Confusion Matrix

Nilai confusion matrix aktual belum diberikan. Tambahkan gambar dan angka confusion matrix dari Stage 5 agar jumlah True Positive, True Negative, False Positive, dan False Negative dapat dibahas secara kuantitatif.

6. MODEL INTERPRETATION

Permutation Feature Importance dihitung menggunakan scoring F1. Satu fitur diacak pada data testing dan perubahan performa model diamati. Nilai yang lebih tinggi berarti performa model lebih bergantung pada fitur tersebut. Nilai importance tidak membuktikan hubungan sebab-akibat.

Peringkat	Fitur	Importance
1	tenure	0,195386
2	InternetService	0,111788
3	Contract	0,111738
4	OnlineSecurity	0,031268
5	TechSupport	0,030313
6	PaymentMethod	0,019230
7	OnlineBackup	0,017469

Peringkat	Fitur	Importance
8	PaperlessBilling	0,016415
9	StreamingMovies	0,013963
10	MultipleLines	0,009875

6.1 Pembahasan

tenure merupakan fitur paling penting dengan importance 0,195386. Berikutnya adalah InternetService (0,111788) dan Contract (0,111738). Hasil ini menunjukkan bahwa informasi masa berlangganan, jenis layanan internet, dan jenis kontrak paling membantu model mempertahankan performa prediksi pada eksperimen ini. Fitur OnlineSecurity, TechSupport, dan PaymentMethod juga memberi kontribusi, tetapi nilainya lebih rendah.

7. REKOMENDASI BISNIS

Retensi berdasarkan masa berlangganan. Perusahaan dapat mengevaluasi pengalaman pelanggan baru dan mempertimbangkan onboarding, dukungan penggunaan, serta program loyalitas yang relevan.

Evaluasi layanan internet. Karena InternetService termasuk fitur penting, perusahaan dapat memantau kualitas koneksi dan keluhan pelanggan berdasarkan jenis layanan.

Evaluasi jenis kontrak. Perusahaan dapat menawarkan pilihan kontrak yang sesuai kebutuhan pelanggan dan menjelaskan manfaat setiap opsi secara transparan.

Gunakan prediksi sebagai alat bantu. Skor model dapat membantu tim retensi menentukan pelanggan yang perlu ditinjau, tetapi keputusan akhir harus mempertimbangkan konteks pelanggan dan hasil verifikasi.

8. KETERBATASAN DAN PENGEMBANGAN

Keterbatasan utama adalah Recall yang masih 52,14%, sehingga sebagian pelanggan churn belum terdeteksi. Evaluasi juga menggunakan satu pembagian train-test; cross-validation dapat digunakan untuk mengukur kestabilan performa. Imputasi median sebelum pemisahan data perlu dipindahkan ke pipeline training untuk mengurangi potensi data leakage. Pengembangan berikutnya dapat mencakup hyperparameter tuning, cross-validation, penyesuaian threshold berdasarkan biaya kesalahan bisnis, serta evaluasi khusus untuk meningkatkan Recall.

9. KESIMPULAN

Tiga algoritma klasifikasi telah dibandingkan untuk prediksi Telco Customer Churn. Logistic Regression memberikan hasil terbaik pada eksperimen ini dengan Accuracy 79,99%, Precision 65,44%, Recall 52,14%, dan F1-Score 58,04%. Permutation Feature Importance menempatkan tenure, InternetService, dan Contract sebagai tiga fitur terpenting. Model dapat menjadi alat bantu untuk mengidentifikasi pelanggan yang perlu mendapat perhatian retensi, tetapi masih perlu penyempurnaan sebelum digunakan dalam operasional.

10. REFERENSI

1. IBM. Telco Customer Churn resources. https://github.com/IBM/telco-customer-churn-on-icp4d

2. scikit-learn documentation. https://scikit-learn.org/stable/user_guide.html

3. pandas documentation. https://pandas.pydata.org/docs/

4. Matplotlib documentation. https://matplotlib.org/stable/

CATATAN SEBELUM PENGUMPULAN

Laporan ini menggunakan metrik evaluasi dan feature importance yang diberikan. Sebelum dikumpulkan, tambahkan jumlah baris/kolom aktual dari Stage 1, angka dan grafik EDA dari Stage 2, serta confusion matrix aktual dari Stage 5. Pastikan dataset, notebook, dan hasil file di GitHub sesuai dengan versi yang dilaporkan.